

Patrones mutacionales en gliomas: ¿Pueden las mutaciones génicas predecir su grado tumoral?



Juan Carlos Correro Malia

Introducción

Los gliomas son tumores heterogéneos del sistema nervioso central, clasificados principalmente en gliomas de bajo grado (LGG) y glioblastomas (GBM), estos últimos caracterizados por su agresividad y mal pronóstico.

La evidencia molecular indica que mutaciones en ciertos genes clave puede ser determinante en su clasificación, lo que ha motivado el interés por evaluar si ciertos patrones mutacionales y la edad pueden explicar cuantitativamente el grado tumoral.

El dataset empleado recoge características clínicas junto con mutaciones en genes relevantes implicados en la progresión de los gliomas. Esto permite su análisis mediante técnicas de ciencia de datos, con el propósito de investigar si estas variables pueden lograr predecir el grado tumoral. En este trabajo se desarrolla un modelo de regresión logística para evaluar esa posible capacidad predictiva.




Figura 1. Comparación histológica entre glioma de bajo grado (izquierda), con menor celularidad y arquitectura más uniforme, y glioma de alto grado (derecha), que muestra mayor densidad celular y atipia. Imágenes obtenidas del Human Protein Atlas.

Pregunta de investigación

¿Pueden ciertos patrones de mutación en genes clave y la edad al diagnóstico predecir el grado tumoral en gliomas?

Hipotesis

Las mutaciones en genes asociados a gliomas de bajo grado (como IDH1, IDH2 y ATRX) reducirán significativamente la probabilidad de que un tumor sea de alto grado (GBM), mientras que mutaciones típicas de glioblastoma (como TP53, PTEN, EGFR o MUC16), junto con una mayor edad al diagnóstico, aumentarán de forma significativa la probabilidad de GBM.

Base de datos

El estudio emplea el “Glioma Grading Clinical and Mutation Features Dataset”, disponible en el UCI Machine Learning Repository.

La base de datos inicial contenía **862 pacientes** y **27 variables**, siendo las filas los pacientes y las columnas las variables. El formato de la base de datos es tabular-CSV. El dataset está distribuido bajo licencia de uso abierto, permitiendo su empleo en investigación.

Análisis exploratorio (EDA)

Permitió caracterizar la estructura del dataset y revisar la calidad de la información disponible. El conjunto está formado por **variables clínicas** y **variables genómicas**. Entre las primeras:

- Grado tumoral (variable categórica: LGG/GBM)
- Edad al diagnóstico (variable categórica: “X years Y days”)
- Proyecto, Identificador, Género, Diagnóstico primario, Raza (variables categóricas: no se emplearon en el modelo).

Las **variables genómicas** consisten en la presencia o ausencia de mutación en 20 genes asociados a gliomas (variables categóricas: MUTATED/NOT_MUTATED)

En cuanto a la **calidad de los datos**, se detectaron valores faltantes en algunas variables.

Procesamiento de los datos

Para garantizar un análisis riguroso y reproducible, se procesaron los datos realizando los siguientes pasos:

- Revisión de integridad del dataset y análisis de ausencia de valores.
- Codificación del grado tumoral como variable binaria: LGG = 0, GBM = 1.
- Conversión de la edad al diagnóstico en una variable numérica continua (años)
- Transformación de las mutaciones en variables binarias, donde “1” es mutado y “0” es no mutado.
- Eliminación de pacientes con valores faltantes en la edad.

Al final del preprocesado, el conjunto final quedó compuesto por **857 pacientes** y **22 variables numéricas** listas para el análisis estadístico y predictivo.




Figura 2. Distribución de pacientes por grado tumoral (LGG vs GBM) en la cohorte.

Interpretación:

Se observa un número mayor de LGG que GBM, implicando una ligera descompensación de clases pero sin comprometer el modelado.




Figura 3. Proporción de mutaciones en los 20 genes analizados en la cohorte.

Interpretación:

IDH1, TP53 y ATRX son los genes más frecuentemente mutados. Genes como PDGFRA o FAT4 tienen una significativamente baja frecuencia, presentando menor utilidad como predictores.




Figura 4. Genes diferencialmente mutados entre LGG y GBM.

Interpretación:

Se pueden diferenciar patrones claros:

- IDH1/IDH2 → predominan en LGG.
- EGFR y PTEN → predominan en GBM.

Apoya la existencia de perfiles mutacionales diferenciales según grado.




Figura 5. Distribución de la edad al diagnóstico en LGG y GBM mediante violines y puntos.

Interpretación:

La edad muestra una separación clara entre grados. Mientras que los pacientes con LGG tienden a ser más jóvenes, los pacientes con GBM son notablemente más mayores, confirmando su relevancia predictiva.

Modelo logístico predictivo

- Se ajustó primero un **modelo completo** con los 20 genes + edad. Este modelo mostró buena capacidad predictiva, pero incluyó predictores no significativos y tuvo problemas de convergencia debido a la alta dimensionalidad relativa al número de eventos.
- Posteriormente se generó un **modelo reducido**, seleccionando únicamente predictores con significancia estadística y relevancia biológica: IDH1, IDH2, TP53, NF1, MUC16 y edad.




Figura 6. Odds Ratios ajustados del modelo reducido (IDH1, IDH2, TP53, NF1, MUC16 y edad).

Interpretación:

- OR < 1: IDH1, IDH2 y NF1 → protegen frente a GBM, típicos de LGG.
- OR > 1: TP53, MUC16 y edad → incrementan la probabilidad de GBM.




Figura 7. Desempeño del modelo reducido (AUC ≈ 0.90).

Interpretación:

El modelo presenta una gran capacidad discriminatoria entre LGG y GBM, manteniendo una mayor simplicidad e interpretabilidad que el modelo completo.

Modelo reducido:

- Mantiene un AUC ≈ 0.90, similar al modelo completo.
- Evita problemas de sobreajuste.
- Mejora la interpretabilidad clínica.
- Consta únicamente de genes realmente informativos.




Figura 8. Matriz de confusión para el conjunto de test.

Interpretación:

El modelo clasifica correctamente la mayoría de casos LGG y GBM, mostrando un gran equilibrio entre sensibilidad y especificidad.

Limitaciones del estudio

- Variable clínica “Grado” no estandarizada para diferentes hospitales/consultas.
- Dataset no incluye información de metilación, expresión génica o CNVs, que aumentarían la capacidad predictiva.
- Reducido poder estadístico en genes con baja frecuencia mutacional.
- Modelo entrenado y evaluado sobre la misma cohorte (train/test split).
- Cohorte independiente no disponible para validar el modelo.

Conclusiones

- Los patrones mutacionales permiten predecir el grado tumoral con alta precisión.
- IDH1, IDH2 y NF1 se asocian fuertemente a LGG.
- TP53, MUC16 y la edad elevada al diagnóstico predicen GBM.
- El modelo reducido (AUC ≈ 0.90) ofrece simplicidad y robustez.
- Los resultados apoyan el uso de perfiles genéticos como herramienta complementaria en la estratificación de los gliomas en el ámbito clínico.

Bibliografía

